

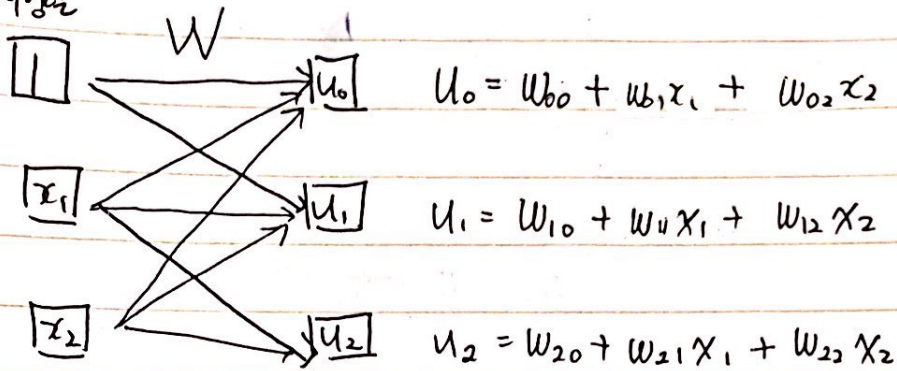
# 09. 로지스틱 회귀 모델 (다중 클래스 분류)

- 모델의 기본 개념

0과 1 사이의 확률값을 출력하는 문항을 여러개로 만들어 사용한다

이 방법은 여러개의 문항을 병렬로 사용하되 확률값이 가장 큰 문항의 클래스를 모델 전체의 예측값으로 간주한다.

- 가중치 개념



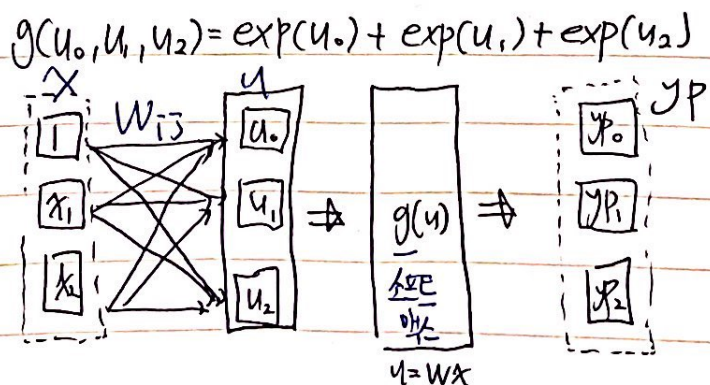
$$u = Wx$$

$$\begin{bmatrix} u_0 \\ u_1 \\ u_2 \end{bmatrix} = \begin{pmatrix} w_{00} & w_{01} & w_{02} \\ w_{10} & w_{11} & w_{12} \\ w_{20} & w_{21} & w_{22} \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix}$$

- 소프트맥스 함수

- 입력은 1차원 벡터, 출력은 1차원 벡터값 함수
- 각 출력 요소는 0부터 1까지의 값을 가짐
- 모든 출력값을 더하면 1이 된다.

$$\begin{cases} y_0 = \frac{\exp(u_0)}{g(u_0, u_1, u_2)} \\ y_1 = \frac{\exp(u_1)}{g(u_0, u_1, u_2)} \\ y_2 = \frac{\exp(u_2)}{g(u_0, u_1, u_2)} \end{cases}$$



- 손실함수

$$y_t = (y_{t_0}, y_{t_1}, y_{t_2})$$

$$y_p = (y_{p_0}, y_{p_1}, y_{p_2})$$

3개 변수를 통해 정의한다.

$$\sum_{i=0}^2 (y_{t_i} \log(y_{p_i}))$$

정답값을 2로 가정하면  $y_t = (0, 0, 1)$

$$L(u) = -\frac{1}{M} \sum_{m=0}^{M-1} \sum_{i=0}^2 (y_{t_i}^{(m)} \log(y_{p_i}^{(m)}))$$

데이터의  
평균을 구해줌

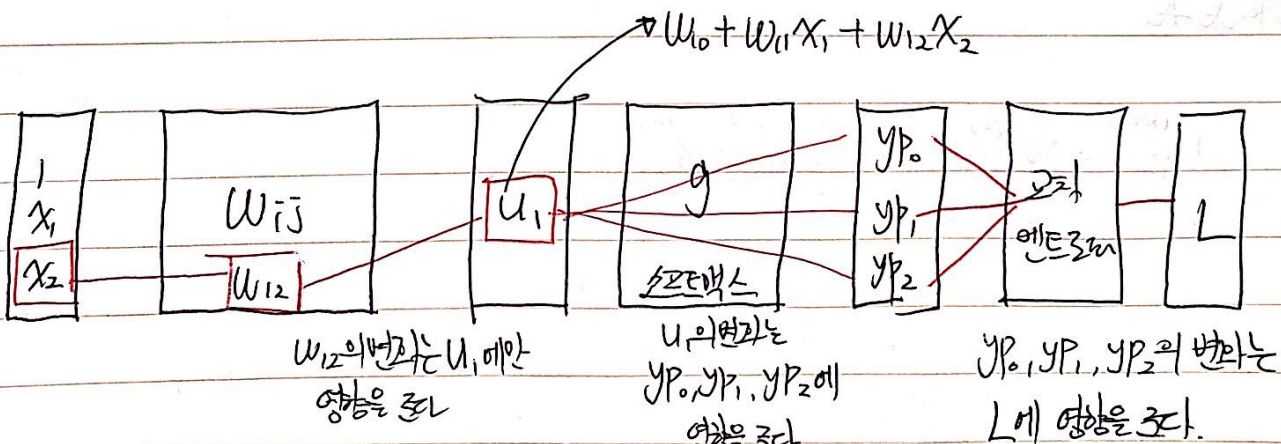
코치엔트로피

- 손실함수의 미분계산

$$y_t^{(m)} \rightarrow y_t = (y_{t_0}, y_{t_1}, y_{t_2})$$

$$y_p^{(m)} \rightarrow y_p = (y_{p_0}, y_{p_1}, y_{p_2})$$

$$\text{코치엔트로피} = -\sum_{i=0}^2 (y_{t_i} \log(y_{p_i}))$$



$$\begin{aligned} \textcircled{1} \frac{\partial L}{\partial w_{12}} &= \frac{\partial L}{\partial u_1} \cdot \frac{\partial u_1}{\partial w_{12}} \\ &= \frac{\partial L}{\partial u_1} \cdot x_2 \end{aligned}$$

Where  $u_1 = w_{10} + w_{11}x_1 + w_{12}x_2$

Backpropagation through the activation function  $g$  (Sigmoid):

$$\frac{\partial L}{\partial y_{p_0}} \cdot \frac{\partial y_{p_0}}{\partial u_1} + \frac{\partial L}{\partial y_{p_1}} \cdot \frac{\partial y_{p_1}}{\partial u_1} + \frac{\partial L}{\partial y_{p_2}} \cdot \frac{\partial y_{p_2}}{\partial u_1}$$

Where the partial derivatives of the sigmoid function are:

- $\frac{\partial y_{p_0}}{\partial u_1} = -y_{p_0} \cdot y_{p_0}$
- $\frac{\partial y_{p_1}}{\partial u_1} = -y_{p_1} \cdot (1 - y_{p_1})$
- $\frac{\partial y_{p_2}}{\partial u_1} = -y_{p_1} \cdot y_{p_2}$



$$\begin{aligned}
 \frac{\partial L}{\partial u_i} &= -\frac{y_{t_0}}{y_{p_0}} \cdot (-y_{p_1} \cdot y_{p_0}) - \frac{y_{t_1}}{y_{p_1}} \cdot y_{p_1} (1 - y_{p_1}) - \frac{y_{t_2}}{y_{p_2}} \cdot (-y_{p_1} \cdot y_{p_2}) \\
 &= y_{t_0} \cdot y_{p_1} - y_{t_1} (1 - y_{p_1}) + y_{t_2} \cdot y_{p_2} \\
 &= -y_{t_1} + y_{p_1} (y_{t_0} + y_{t_1} + y_{t_2}) \\
 &= y_{p_1} - y_{t_1} \quad \text{항상 1이다.}
 \end{aligned}$$

$$\therefore \frac{\partial L}{\partial u_i} = y_{p_i} - y_{t_i} \quad (i=0, 1, 2)$$

위적으로 속을 생각하기 위해  $y_{p_i} - y_{t_i} = y_{d_i}$  라 정의

$$\frac{\partial L}{\partial u_i} = y_{d_i} \quad (i=0, 1, 2)$$

$$\frac{\partial L}{\partial u_{12}} = x_2 \frac{\partial L}{\partial u_1} = x_2 \cdot y_{d_1}$$

$$\frac{\partial L}{\partial w_{ij}} = x_j \cdot y_{d_i}$$

- 경사하강법 적용

$$w_{ij}^{(k+1)} = w_{ij}^{(k)} - \frac{\alpha}{M} \sum_{m=0}^{M-1} y_{d_i}^{(m)} \cdot x_j^{(m)}$$